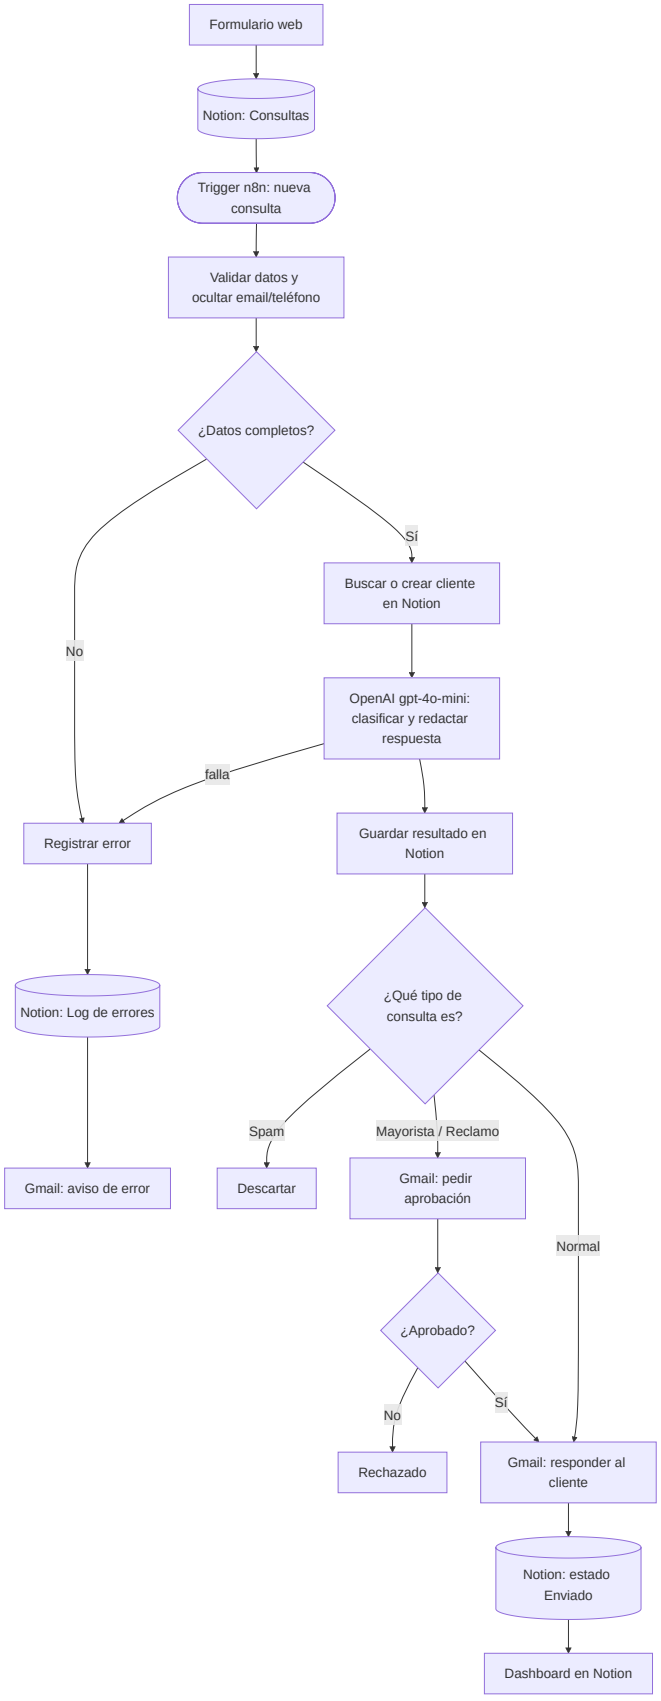
Raíz Viva – Ecosistema de Automatización IA

Orquestador	Base de datos	Procesamiento IA	Canal de salida
n8n Cloud	Notion (3 bases relacionadas)	OpenAI gpt-4o-mini	Gmail (cliente + HITL)

Caso de uso. Raíz Viva es un vivero online ficticio (todos los datos de este proyecto son inventados). Recibe por su web consultas de compradores minoristas, pedidos mayoristas de paisajistas y otros viveros, reclamos por envíos y dudas sobre el cuidado de plantas. Responder a mano cada consulta consume horas y se pierden pedidos grandes entre mensajes triviales y spam.

Solución. Un ecosistema que funciona de punta a punta sin intervención manual: la consulta entra a la base de datos, n8n la detecta, la IA la clasifica (categoría, prioridad y sentimiento) y redacta una respuesta. Las respuestas simples se envían solas. Las acciones críticas (pedidos mayoristas, reclamos, sentimiento negativo o prioridad alta) se detienen hasta que una persona las aprueba. Todo queda registrado en Notion, que también funciona como dashboard para la dueña del negocio.

1. Mapa de arquitectura del sistema



Capa	Componentes
Trigger de entrada	Notion Trigger: solo detecta páginas nuevas en *Consultas* (no ediciones), con polling cada minuto. De esta forma se evita procesar el historial y gastar operaciones de más.
Routers de distribución	`¿Procesable?` (anti-bucle), `¿Datos completos?`, `¿Cliente existe?`, `¿Respuesta IA válida?`, `Router` (Spam / HITL / automática) y `¿Aprobado por humano?`.
APIs integradas	Notion API (lectura y escritura en 3 bases), OpenAI Chat Completions, Gmail (envío al cliente, aprobación *send-and-wait* y alertas). Slack y WhatsApp están documentados como canales alternativos (sección 6).
Nodo de IA	OpenAI `gpt-4o-mini` con salida JSON forzada (`response_format: json_object`), `max_tokens` y temperatura tomados de *Configuración*.
Destino final	Email al cliente, registro completo en Notion y Dashboard de Control Ejecutivo.

Inventario de nodos (flujo principal, 33 nodos funcionales)

#	Nodo	Función
1	Trigger · Nueva consulta en Notion	Disparador por página nueva en *Consultas*.
2	Configuración	Variables del sistema: negocio, email del responsable, modelo, max_tokens, temperatura, máximo de intentos, IDs de bases. Ningún otro nodo tiene estos valores escritos a mano.
3	Normalizar y minimizar datos	Lee las propiedades por nombre, valida el email y el largo del mensaje, y anonimiza emails y teléfonos antes de enviarlos a la IA.
4–5	¿Procesable? / ¿Datos completos?	Filtro anti-bucle (estado y contador de intentos) y validación de datos obligatorios.
6–9	Marcar Pendiente · Buscar cliente · ¿Cliente existe? · Crear cliente · Vincular	Memoria relacional: deduplica clientes por email y relaciona la consulta con su cliente.
10–13	Construir prompt · IA · Parsear · ¿Válida?	Prompt dinámico → OpenAI → lectura de `choices[0].message.content` → validación de tipos y valores.
14–15	Guardar resultado IA · Router	Escribe la clasificación en Notion y deriva la consulta.
16–21	Descartar spam · Esperando aprobación · Gmail HITL · ¿Aprobado? · Aprobado / Rechazado	Semáforo de validación humana.
22–23	Gmail · Responder al cliente · Marcar Enviado	Salida final; guarda el `threadId` del hilo de Gmail y la fecha de respuesta.
24–31	Error · (4 rutas) · Unificar error · Registrar en Log · Marcar Error · Alertar	Rutas de contingencia.

2. Manual operativo de estructuras de datos

El "cerebro relacional" vive en Notion, en la página *Raíz Viva – Ecosistema de Automatización IA*, con tres bases relacionadas entre sí. El esquema se generó dándole instrucciones a una IA (Claude, conectado a Notion por MCP, que cumple el mismo papel que Omni AI en Airtable). Este es el prompt que se usó:

```
"Creá en Notion la memoria de un sistema de atención al cliente para un vivero online ficticio
llamado Raíz Viva. Necesito 3 bases relacionadas: Clientes (deduplicados por email), Consultas
(con estados Pendiente → Procesado por IA → Esperando aprobación → Aprobado por Humano → Enviado,
más Error, Rechazado y Descartado; categoría, prioridad y sentimiento asignados por IA, respuesta
propuesta, tokens, modelo, Thread ID de Gmail y un contador de intentos anti-bucle) y Log de
errores relacionado con Consultas. Agregá fórmulas para medir la tasa de éxito y la de error."
```

Tabla Consultas (tabla central)

Propiedad	Tipo	Quién la escribe	Uso
Asunto	Título	Cliente (formulario)	Asunto de la consulta
Nombre del cliente · Email remitente · Teléfono · Mensaje	Texto · Email · Teléfono · Texto	Cliente	Datos de entrada
Estado	Select	n8n / humano	Pendiente · Procesado por IA · Esperando aprobación · Aprobado por Humano · Rechazado por Humano · Enviado · Error · Descartado (spam)
Categoría · Prioridad · Sentimiento	Select	IA	Clasificación
Resumen IA · Respuesta propuesta	Texto	IA	Resumen y borrador de respuesta
Requiere aprobación	Checkbox	n8n	Semáforo HITL
Modelo IA · Tokens usados	Select · Número	n8n	Control de costos
Thread ID · Fecha de respuesta	Texto · Fecha	n8n	Trazabilidad del hilo de Gmail
Intentos	Número	n8n	Anti-bucle (máximo 3)
Cliente	Relación ↔ Clientes	n8n	Evita datos aislados
Errores	Relación ↔ Log de errores	n8n	Historial de fallas por consulta
Éxito (%) · Error (%)	Fórmula	Notion	100 si el estado es Enviado / Error; su promedio da la tasa del dashboard
ID · Recibida	ID único (CON-) · Fecha de creación	Notion	Identificación y auditoría

Clientes	
Nombre	Título
Email	Email (clave de deduplicación)
Teléfono	Teléfono (+54...)
Tipo de cliente	Minorista · Mayorista · Paisajista · Desconocido
Consultas	Relación ↔ Consultas
ID · Alta	CLI- · Fecha de creación

Log de errores	
Error	Título
Tipo	Datos faltantes · API de IA · Respuesta IA inválida · Notion · Gmail · Límite de reintentos
Nodo · Detalle · Ejecución n8n	Texto
Consulta	Relación ↔ Consultas
Resuelto · Fecha	Checkbox · Fecha de creación

Sincronización: la única fuente que escribe en las bases es el flujo de n8n (más la aprobación humana). No hay sincronizaciones paralelas que puedan pisar datos.

Esquemas JSON de transferencia de datos

① Notion → n8n (Trigger, recortado)

```
{
  "id": "1a2b…",
  "url": "https://www.notion.so/…",
  "properties": {
    "Asunto": { "type": "title",
      "title": [{ "plain_text": "Pedido 200
suculentas" }] },
    "Email remitente": { "type": "email",
      "email": "lucia@paisajes-ficticios.com"
},
    "Mensaje": { "type": "rich_text",
      "rich_text": [{ "plain_text": "Hola, …"
}] },
    "Estado": { "type": "select", "select":
null },
    "Intentos": { "type": "number", "number":
null }
  }
}
```

② n8n → OpenAI (request)

```
{
  "model": "{{ Configuración.modelo }}",
  "max_tokens": 500,
  "temperature": 0.3,
  "response_format": { "type": "json_object"
},
  "messages": [
    { "role": "system", "content": "Sos el
asistente de
      {{negocio}}… devolvé SOLO JSON…" },
    { "role": "user", "content": "Asunto: …
\nMensaje:
      … escribime a [EMAIL] o al [TEL]" }
  ]
}
```

③ OpenAI → n8n (Message.Content parseado)

```
{
  "categoria": "Pedido mayorista",
  "prioridad": "Alta",
  "sentimiento": "Positivo",
  "resumen": "Paisajista pide 200 suculentas
             con envío a Córdoba",
  "respuesta": "Hola Lucía, ¡gracias por
    escribirnos! … Equipo de Raíz Viva"
}
+ usage.total_tokens → "Tokens usados"
```

④ Gmail send-and-wait → n8n

```
{ "data": { "approved": true } }
```

⑤ n8n → Gmail (cliente) → Notion

```
// respuesta de Gmail
{ "id": "18f…", "threadId": "18f…",
  "labelIds": ["SENT"] }
// update en Notion
{ "Estado": "Enviado",
  "Thread ID": "18f…",
  "Fecha de respuesta": "2026-11-08T14:05:00-
03:00" }
```

⑥ Registro en Log de errores

```
{ "titulo": "Falla de la API de OpenAI",
  "tipo": "API de IA",
  "nodo": "IA · Clasificar y redactar
(OpenAI)",
  "detalle": "401 Incorrect API key…",
  "ejecucion": "1234", "page_id": "1a2b…" }
```

3. Estrategia de optimización de costos y recursos

Cuadro comparativo de modelos

Precios de lista por millón de tokens (USD), consultados en noviembre de 2026; conviene verificarlos en las páginas oficiales antes de usar el sistema en producción. Estimación por consulta: ~650 tokens de entrada (prompt de sistema + mensaje) y ~250 de salida.

Modelo	Entrada / 1M	Salida / 1M	Costo por consulta	1.000 consultas/mes	Fortaleza
gpt-4o-mini ✔	0,15	0,60	≈ 0,00025	≈ 0,25	Clasificación y redacción corta, muy barato
gpt-4o	2,50	10,00	≈ 0,0041	≈ 4,13	Razonamiento general
Claude Haiku 4.5	1,00	5,00	≈ 0,0019	≈ 1,90	Rápido, buen español
Claude Sonnet 4.5	3,00	15,00	≈ 0,0057	≈ 5,70	Lectura densa de textos largos, matices

Matriz de decisión estratégica

Tipo de tarea	Ejemplo en Raíz Viva	Modelo / modo	Justificación
Mecánica (alto volumen, salida estructurada)	Clasificar categoría, prioridad y sentimiento, y redactar respuestas de ≤120 palabras	gpt-4o-mini en tiempo real	La tarea es de etiquetado y plantilla. Cuesta unas 16 veces menos que gpt-4o y con JSON forzado su precisión alcanza.
Lectura densa	Reclamos largos con historial, listados de pedidos mayoristas, condiciones comerciales de proveedores en PDF	Claude Sonnet (ruta de escalamiento, fase 2)	Mejor comprensión de textos extensos y de matices de tono. Se activaría solo cuando el mensaje supere los 1.500 caracteres (menos del 5% del volumen), así que el impacto en el costo es marginal.
Masiva, no urgente	Informe mensual: análisis de todas las consultas del mes para detectar temas frecuentes, FAQs nuevas y causas de reclamos	Batch API (OpenAI o Anthropic Message Batches)	No necesita respuesta inmediata (entrega en hasta 24 h) y tiene un 50% de descuento sobre el precio de lista.

> Certificación del 50% de ahorro (Batch). Informe mensual sobre 1.000 consultas (≈1.500 tokens de entrada y 300 de salida cada una) con Claude Sonnet 4.5: en tiempo real cuesta 1.000 × (1.500 × 3 + 300 × 15) / 1M = USD 9,00; por Batch API, (1,50 + 7,50) × 0,5 × 1.000 / 1.000 = USD 4,50, es decir, un 50% de ahorro. Con Claude Haiku 4.5 sería USD 3,00 contra USD 1,50.

Otras optimizaciones implementadas

- max_tokens = 500 y respuesta de ≤120 palabras pedida en el prompt: limita el gasto en tokens de salida, que son los más caros.
- Minimización del input: solo se envían el asunto y el mensaje (recortado a 2.000 caracteres). No se envía el email, el teléfono ni el historial.
- El trigger solo toma páginas nuevas y el filtro anti-bucle evita reprocesar: ninguna consulta se manda a la IA más de 3 veces.

- Validación previa: los datos incompletos no llegan a la IA, así que no se paga por procesar consultas basura.
- Registro de tokens en cada consulta, para auditar el costo real desde Notion.

4. Malla de seguridad, privacidad y resiliencia

Políticas de minimización de datos

Medida	Cómo se aplica
Minimización	La IA recibe solo el asunto, el mensaje y el primer nombre (para el saludo). El email y el teléfono quedan en Notion y nunca salen hacia OpenAI.
Anonimización	Si el cliente escribe datos de contacto dentro del mensaje, el nodo *Normalizar y minimizar datos* los reemplaza por `[EMAIL]` y `[TEL]` con expresiones regulares antes de llamar a la IA.
Trazabilidad	Cada consulta guarda modelo, tokens, estado, fecha y Thread ID; cada falla queda en el Log con nodo, detalle y número de ejecución.
Retención	Política propuesta: las consultas descartadas como spam se eliminan a los 30 días y los datos de clientes inactivos se revisan cada 12 meses, en línea con la Ley 25.326 de Protección de Datos Personales (Argentina).
Credenciales	Las API keys se guardan solo en el gestor de credenciales de n8n; el JSON exportado no las contiene. Las capturas se toman con las keys ocultas.
Datos ficticios	Todas las pruebas usan clientes inventados.

Rutas de contingencia (Error Handlers en n8n)

En n8n, el equivalente de las directivas *Resume* / *Break* de Make es la configuración On Error de cada nodo: `Continue (using error output)` funciona como Resume (el flujo sigue por una ruta alternativa) y `Stop workflow` como Break (detiene la ejecución y dispara el flujo de errores global).

Punto de falla	Configuración	Qué pasa
Datos faltantes (email inválido, mensaje corto)	IF *¿Datos completos?* → rama "no"	No se llama a la IA. Se registra en el Log (*Datos faltantes*), la consulta pasa a `Error` y se alerta por email.
API de OpenAI caída, timeout o key inválida	Retry on Fail: 3 intentos cada 3 s · timeout 30 s · On Error: Continue (error output) ≈ Resume	Tras 3 intentos fallidos, la falla se registra en el Log (*API de IA*) y se alerta al responsable. El flujo no se rompe.
La IA devuelve un JSON inválido o una categoría inexistente	Code *Parsear* con try/catch + IF *¿Respuesta IA válida?*	Se registra en el Log (*Respuesta IA inválida*) con el contenido recibido. No se envía nada al cliente.
Gmail no puede enviar al cliente	On Error: Continue (error output)	Se registra en el Log (*Gmail*) y la consulta queda en `Error` para reenviarla a mano.
Cualquier otra falla no prevista	Workflow Settings → Error Workflow = "Manejador global de errores" ≈ Break	El Error Trigger registra la falla en Notion y envía una alerta crítica con el link a la ejecución.

Semáforos de validación humana (Human-in-the-loop)

Para evitar el "efecto metralleta" (que la IA le responda a un cliente algo incorrecto en una situación sensible), el flujo se detiene antes de contactar al cliente cuando se cumple alguna de estas condiciones:

Semáforo	Riesgo que mitiga
Categoría = Pedido mayorista	Compromisos comerciales (precios, volúmenes, plazos) que la IA no debe asumir.
Categoría = Reclamo	Riesgo legal y reputacional (Ley 24.240 de Defensa del Consumidor); una respuesta incorrecta puede escalar el conflicto.
Sentimiento = Negativo	Clientes molestos: el tono importa y la IA puede sonar automática.
Prioridad = Alta	Urgencias que pueden requerir una acción concreta, más allá de un email.

En ese caso, el estado pasa a `Esperando aprobación` y el nodo Gmail · send-and-wait le manda a la responsable un email con el mensaje original, la clasificación, la respuesta propuesta y dos botones: Aprobar y enviar o Rechazar. La ejecución queda en pausa hasta que alguien hace clic. Si se aprueba, la respuesta se envía y la consulta queda `Aprobado por Humano → Enviado`; si se rechaza, queda `Rechazado por Humano` para responderla a mano. Además, el prompt le prohíbe a la IA inventar precios, stock o plazos (control de alucinaciones).

Check de seguridad

Pregunta	Respuesta
¿El flujo tiene un filtro para evitar bucles infinitos?	Sí. Hay tres capas: (1) el trigger solo detecta páginas *nuevas*, así que las actualizaciones del propio flujo no lo vuelven a disparar; (2) el IF *¿Procesable?* solo deja pasar consultas en estado vacío o Pendiente; (3) el contador *Intentos* corta el procesamiento al llegar a 3.
¿Se comparan tipos de datos correctos en los filtros?	Sí. Todos los IF y Switch usan validación de tipos estricta: booleanos contra booleanos (`procesable`, `datos_completos`, `ok`, `requiere_aprobacion`, `data.approved`) y números convertidos con `Number()` antes de compararlos (`intentos < max_intentos`).
¿El prompt de IA es dinámico y usa variables del sistema?	Sí. El nodo *Construir prompt dinámico* arma el prompt con `negocio`, `modelo`, `max_tokens` y `temperatura` de *Configuración*, y con `primer_nombre`, `asunto` y `mensaje_anonimizado` de cada consulta.

5. Dashboard de Control Ejecutivo

Es la misma página de Notion del proyecto, publicada en la web en modo solo lectura. Ahí la dueña del negocio puede ver la operación en tiempo real, sin entrar a n8n. Como el plan gratuito de Notion limita los gráficos, el dashboard usa una tabla de consultas *agrupada por estado*: Notion muestra la cantidad de consultas de cada grupo, y de ahí salen los KPIs.

Indicador	Dónde se ve	Resultado de las pruebas
Consultas totales	Suma de todos los grupos	6
Tasa de éxito	Grupo *Enviado* sobre el total (columna *Éxito (%)* = 100 en cada consulta enviada)	2 de 6 (33%)
Tasa de error	Grupo *Error* sobre el total (columna *Error (%)* = 100 en cada consulta con error)	2 de 6 (33%), ambas provocadas a propósito en el test de estrés
Control humano	Grupos *Esperando aprobación* y *Rechazado por Humano*, y columna *Requiere aprobación*	2 consultas frenadas por el semáforo HITL (1 aprobada, 1 rechazada)
Spam filtrado	Grupo *Descartado (spam)*	1
Log de errores	Tabla de la base Log de errores	Fallas registradas, con tipo, nodo y fecha

Link al dashboard (solo lectura): [crawling-cayenne-74e.notion.site/Ra-z-Viva-Ecosistema-de-Automatizaci-n-IA]

6. Canales alternativos (escalabilidad)

- Slack: la aprobación HITL puede pasarse al nodo *Slack · Send and Wait* en un canal #aprobaciones, respondiendo en el hilo del mensaje original (`thread_ts`) para que la conversación quede ordenada.
- WhatsApp Business API: para mensajes proactivos (fuera de la ventana de 24 h) se necesita una plantilla aprobada por Meta y el número en formato internacional (`+5493515551234`). Por eso la base guarda el teléfono con el prefijo `+54`.

7. Test de estrés (6 ejecuciones, mínimo pedido: 5)

#	Caso	Entrada	Resultado esperado
1	Camino feliz	"¿Tienen potus? ¿Hacen envíos a Rosario?"	Venta minorista → respuesta automática → `Enviado`
2	HITL aprobado	Paisajista pide 200 suculentas	Pedido mayorista → email de aprobación → Aprobar → `Enviado`
3	HITL rechazado	Reclamo enojado: "llegó la maceta rota"	Reclamo, sentimiento negativo → Rechazar → `Rechazado por Humano`
4	Camino infeliz: datos incompletos	Email "juan@" y mensaje "hola"	Sin llamada a la IA → Log *Datos faltantes* → `Error` + alerta
5	Camino infeliz: falla de API	Credencial de OpenAI con una key inválida	3 reintentos → Log *API de IA* → `Error` + alerta
6	Spam	"GANÁ DINERO FÁCIL hacé clic acá"	`Descartado (spam)`, sin respuesta

Las capturas de cada ejecución están en la carpeta `evidencias/` del repositorio.